

Trasporto Ottimale nel Domain Adaptation

Alessandro Maria Gullotti

Indice

1	Introduzione	2
2	Fondamenti teorici	5
2.1	Formulazione discreta	5
2.1.1	Distanza di p -Wasserstein e divergenza KL	5
2.2	Regolarizzazione di Cuturi	6
2.3	Proprietà di Differenziabilità	7
2.4	L'Algoritmo di Sinkhorn	7
3	Optimal Transport per il Domain Adaptation	9
3.1	Allineamento delle distribuzioni tramite Optimal Transport (OTDA) . . .	9
3.2	JDOT	10
3.3	DeepJDOT	11
3.4	Rappresentazioni prototipiche	11
3.5	Adattamento nel caso multi-sorgente	12
3.6	Allineamento tramite prototipi multi-dominio	12
3.7	Multi-Source DeepJDOT	13
3.8	Baricentri di Wasserstein per il Domain Adaptation Multi-Sorgente	14
4	Esperimento	15
4.1	Dataset e task	15
4.1.1	Quantificazione empirica del domain shift	15
4.2	Scelte sperimentali	16
4.3	Metodi	17
4.3.1	Baseline (ce)	17
4.3.2	CE con ricalibrazione delle statistiche BatchNorm (ce_{BN})	17
4.3.3	OT con prototipi di classe fusi ($proto_{OT}$)	18
4.3.4	OT con prototipi di classe pairwise ($proto_{OT}^{PW}$)	18
4.3.5	DeepJDOT aggregato ($deepjdot$)	18
4.3.6	DeepJDOT pairwise multi-sorgente ($deepjdot_{PW}$)	18
4.3.7	Baricentro di Wasserstein ($Wbarycenters_{OT}$)	18
4.4	Risultati e discussione	19
4.5	Conclusioni	21

1 Introduzione

Ogni qualvolta si desidera spostare risorse da una configurazione spaziale di partenza ad una di arrivo, l'obiettivo è la minimizzazione di qualche forma di energia spesa per effettuare tali trasferimenti. La teoria del trasporto ottimale tratta l'omonimo problema, ossia si impone di capire come minimizzare il costo complessivo del trasporto necessario.

La prima formulazione del problema risale al 1781, in seguito alla pubblicazione di Gaspard Monge "Mémoire sur la théorie des déblais et des remblais", una memoria che trattava di questioni di ingegneria militare legate alla costruzione di fortificazioni. Si trattava di spostare convenientemente il volume di terra estratto dagli scavi di trincee o fossati (déblais, "scavo") per destinarlo alla realizzazione di bastioni (remblais, "riporto"). Assumendo che il costo per spostare una quantità di massa coincidesse con la distanza del tragitto per la massa spostata (lavoro), Monge formalizzò il problema di associare in modo ottimale i punti di scavo a quelli di riporto, in modo da minimizzare il lavoro complessivo. [1]

Matematicamente, il problema di Monge si può esprimere in notazione moderna nel seguente modo:

date due misure di probabilità μ e ν su $\mathbb{R}^d$ trova (se esiste) una mappa $T : \mathbb{R}^d \rightarrow \mathbb{R}^d$ che soddisfi il vincolo di push-forward

$$T_{\#}\mu = \nu \quad (1)$$

ossia

$$\nu(A) = \mu(T^{-1}(A)), \quad \forall A \subseteq \mathbb{R}^d \text{ boreliano}, \quad (2)$$

e che minimizzi il funzionale di costo

$$M_c(T) := \int_{\mathbb{R}^d} c(x, T(x)) d\mu(x). \quad (3)$$

Sebbene Monge intuì alcune proprietà geometriche che tale mappa di trasporto doveva soddisfare (in dimensione piccola), il problema dell'esistenza di una mappa ottimale rimase un problema irrisolto per oltre 150 anni [1].

La formulazione di Monge presenta infatti delle difficoltà in quanto è non convessa e fallisce ogniquale volta la misura sorgente contenga masse atomiche che devono essere frazionate verso più destinazioni.¹

Negli anni '40 del Ventesimo secolo, grazie alle pressanti necessità industriali, il problema generò nuovo interesse ed un contributo decisivo arrivò dal matematico sovietico

¹Si consideri, a titolo esemplificativo, una distribuzione sorgente data da una singola massa atomica posizionata in un punto $x_0 \in \mathbb{R}^d$, espressa come misura di Dirac $\mu = \delta_{x_0}$, e una distribuzione target formata da due masse atomiche uguali collocate in due punti distinti $y_1, y_2 \in \mathbb{R}^d$, ovvero $\nu = \frac{1}{2}\delta_{y_1} + \frac{1}{2}\delta_{y_2}$. Poiché una mappa di trasporto $T : \mathbb{R}^d \rightarrow \mathbb{R}^d$ è una funzione, l'immagine del punto x_0 tramite T deve essere un singolo punto $T(x_0) \in \mathbb{R}^d$. Di conseguenza, la misura trasportata $T_{\#}\mu = \delta_{T(x_0)}$ sarà sempre una massa concentrata in un unico punto e non potrà mai coincidere con ν , che distribuisce la massa a metà tra due posizioni distinte. In questo scenario non esiste quindi alcuna mappa T in grado di soddisfare il vincolo di push-forward $T_{\#}\mu = \nu$.

Mappa di Monge




Figura 1: Impossibilità di trasportare una massa atomica concentrata in un punto verso due destinazioni distinte.

Leonid Kantorovich che lo riformulò come un problema di programmazione lineare.

Fondamentalmente, anziché cercare una mappa di trasporto T puntuale, Kantorovich descrisse il movimento tramite una probabilità congiunta γ sullo spazio prodotto $\mathcal{X} \times \mathcal{Y}$, le cui proiezioni marginali coincidono con le misure originali. Il costo da minimizzare divenne così il funzionale lineare

$$\mathcal{L}_c(\mu, \nu) \triangleq \min_{\gamma \in \Pi(\mu, \nu)} \int_{\mathcal{X} \times \mathcal{Y}} c(x, y) d\gamma(x, y) = \min_{\gamma \in \Pi(\mu, \nu)} \langle C, \gamma \rangle \quad (4)$$

dove $\Pi(\mu, \nu) = \{\gamma \in \mathcal{M}_+^1(\mathcal{X} \times \mathcal{Y}) : P_{\mathcal{X}\#}\gamma = \mu, P_{\mathcal{Y}\#}\gamma = \nu\}$ è lo spazio di ricerca dato dall'imposizione dei vincoli push-forward, che è convesso e compatto. La convessità dell'insieme di ammissibilità e la linearità della funzione obiettivo garantiscono l'esistenza del minimo.




Figura 2: Rappresentazione del trasporto ottimale. Le masse di probabilità della configurazione iniziale (nodi rossi) vengono trasferite verso la configurazione di arrivo (nodi blu) tramite traiettorie che minimizzano il costo complessivo di spostamento.

Sotto opportune ipotesi di regolarità e costo quadratico $c(x, y) = |x - y|^2$, dal lavoro di Brenier [2], è noto che la mappa ottimale è il gradiente di una funzione convessa u , cioè

$T^* = \nabla u$, dove u è una funzione che soddisfa l'equazione di Monge-Ampère ²

$$\det(\nabla^2 u(x)) = \frac{f(x)}{g(\nabla u(x))} \quad (5)$$

Questo risultato stabilisce un legame profondo tra il trasporto ottimo ed una classica equazione alle derivate parziali. Questo ed altri collegamenti hanno reso il trasporto ottimo un campo di ricerca molto attivo nell'analisi funzionale e nella teoria delle PDE ellittiche.

Il relativamente recente passaggio verso le applicazioni nel machine learning è stato sbloccato da una riformulazione del programma lineare associato alla formulazione di Kantorovich, che ha complessità $\mathcal{O}(n^3 \log n)$, molto onerosa per le dimensioni tipiche dei dataset utilizzati.

L'idea di Marco Cuturi ([3]) fu quella di aggiungere al funzionale di costo un termine perturbativo proporzionale all'entropia $-\varepsilon H(\gamma)$, con $H(\gamma) = -\sum_{ij} \gamma_{ij} \log \gamma_{ij}$ con $\varepsilon > 0$ parametro di regolarizzazione. Si può dimostrare ([7]) che il problema perturbato

$$\min_{\gamma \in \Pi(\mu, \nu)} \langle C, \gamma \rangle - \varepsilon H(\gamma) \quad (6)$$

ammette una soluzione unica della forma $\gamma_{ij}^* = u_i e^{-C_{ij}/\varepsilon} v_j$, dove i vettori u, v si determinano tramite l'algoritmo iterativo di Sinkhorn. Questa procedura riduce la complessità a $\mathcal{O}(n^2)$ per iterazione e rende il calcolo parallelizzabile su GPU. Questa nuova trattabilità numerica, unita alla differenziabilità rispetto ai parametri del modello, ha aperto le porte all'utilizzo dell'OT nel deep learning.

Ad oggi le applicazioni più consolidate riguardano l'allineamento di domini nel contesto dell'adattamento non supervisionato (es. DeepJDOT [5]) e l'addestramento di reti generative avversariali basate sulla distanza di Wasserstein (WGAN [6]).

Il presente lavoro si concentra sull'impiego di metodi basati sul trasporto ottimale nel contesto della domain adaptation non supervisionata multisorgente.

Dopo aver introdotto per completezza il quadro storico ed i concetti più rilevanti per la teoria dell'OT nell'apprendimento automatico, vengono analizzati diversi metodi che utilizzano l'OT per allineare le rappresentazioni fra domini differenti. La parte sperimentale confronta queste strategie sul dataset PACS, utilizzando tre domini come sorgenti e il quarto come target non supervisionato.

L'obiettivo fondamentale è quindi valutare se e in quale misura l'allineamento mediante trasporto ottimale possa migliorare la generalizzazione verso domini caratterizzati da un forte domain shift. Contestualmente verrà indagato in che misura l'efficacia dell'adattamento dipenda dal livello in cui viene rappresentata la misura sorgente (puntuale in DeepJDOT, per classi nei metodi prototipici e continuo-distributivo nei baricentri di Wasserstein) e dalla strategia di gestione multi-dominio, confrontando l'allineamento globale con formulazioni pairwise introdotte per evitare eventuali interferenze tra stili visivi diversi.

² f e g rappresentano le densità di probabilità rispettivamente della misura sorgente μ e della misura bersaglio ν rispetto alla misura di Lebesgue su $\mathbb{R}^d$

2 Fondamenti teorici

2.1 Formulazione discreta

Nelle applicazioni, le distribuzioni continue vengono approssimate tramite campioni empirici o misure discrete. Dati un insieme di punti di supporto $\{x_1, \dots, x_n\} \subset \mathcal{X}$ e un vettore di pesi $a \in \Sigma_n$, dove $\Sigma_n \triangleq \{a \in \mathbb{R}_+^n : \sum_{i=1}^n a_i = 1\}$ indica il semplice di probabilità n -dimensionale, la cui misura associata è espressa da

$$\alpha = \sum_{i=1}^n a_i \delta_{x_i} \quad (7)$$

Analogamente, si definisce la misura target $\beta = \sum_{j=1}^m b_j \delta_{y_j}$ supportata su $\{y_1, \dots, y_m\} \subset \mathcal{Y}$ con vettori di peso $b \in \Sigma_m$.

Definite α e β , il problema di Monge è quello di trovare una mappa $T : \mathcal{X} \rightarrow \mathcal{Y}$ che associ a ciascun punto x_i un punto y_j e che riassegni in modo deterministico la massa della configurazione iniziale in quella finale, minimizzando il costo

$$\min_T \left\{ \sum_{i=1}^n c(x_i, T(x_i)) : T_{\#}\alpha = \beta \right\} \quad (8)$$

dove la funzione $c(x, y)$ quantifica il costo per spostare una singola unità di massa tra x e y .

La non convessità di questa formulazione non permette in generale di garantire l'esistenza di una mappa di trasporto. Ad esempio, se l'origine ha meno nodi rispetto alla destinazione ($n < m$), non esiste alcuna mappa che garantisca l'assegnazione corretta, poiché non è consentito dividere la massa originaria inviandola a target multipli.

Nel rilassamento di Kantorovich non c'è nessuna restrizione che impone che $n = m$. Per tali misure, la matrice dei costi è descritta da $C \in \mathbb{R}_+^{n \times m}$, con $C_{i,j} = c(x_i, y_j)$, e il politopo dello spazio di ricerca si riduce all'insieme delle matrici di trasporto $P \in \mathbb{R}_+^{n \times m}$ (che è la distribuzione congiunta dello spazio di partenza e di arrivo, in cui il generico elemento $P_{i,j} \geq 0$ indica la frazione di massa trasferita dal punto x_i al punto y_j). Nel discreto il problema di Kantorovich corrisponde al programma lineare

$$L_C(a, b) = \min_{P \in U(a, b)} \langle P, C \rangle = \sum_{i=1}^n \sum_{j=1}^m P_{i,j} C_{i,j} \quad (9)$$

dove

$$U(a, b) = \{P \in \mathbb{R}_+^{n \times m} : P\mathbf{1}_m = a \quad \text{e} \quad P^\top \mathbf{1}_n = b\} \quad (10)$$

2.1.1 Distanza di p -Wasserstein e divergenza KL

Se la funzione di costo soddisfa $c(x, y) = d(x, y)^p$ con $p \geq 1$, dove $d(\cdot, \cdot)$ è una metrica valida sullo spazio $\mathcal{X}$, il valore ottimo di (9) definisce la distanza di p -Wasserstein

$$\mathcal{W}_p(\alpha, \beta) := \left(\min_{P \in U(a, b)} \sum_{i,j} P_{i,j} d(x_i, y_j)^p \right)^{1/p} \quad (11)$$

La metrica di Wasserstein, oltre alla simmetria ed alla disuguaglianza triangolare, possiede una proprietà fondamentale che la distingue dalle ϕ -divergenze tradizionali usate nel Deep Learning (come la divergenza di Kullback-Leibler e la divergenza di Jensen-Shannon), ossia la proprietà di rimanere regolare e continua anche quando i supporti delle distribuzioni sono disgiunti.

Per illustrare il concetto, consideriamo due distribuzioni con supporti disgiunti, date da due masse atomiche $\alpha = \delta_x$ e $\beta = \delta_y$ con $x \neq y$.

- La divergenza di Kullback-Leibler $KL(\alpha \parallel \beta)$ assume valore $+\infty$, e la divergenza $JS(\alpha \parallel \beta)$ assume il valore costante $\log 2$. Di conseguenza, i gradienti rispetto alle posizioni dei supporti sono identicamente nulli ($\nabla_x JS = 0$), rendendo impossibile l'ottimizzazione basata sulla discesa del gradiente.
- La distanza di Wasserstein, invece, si calcola esplicitamente dalla definizione come (osservando che l'insieme delle matrici ammissibili $U(a, b)$ contiene l'unica matrice scalare $P = 1$)

$$\mathcal{W}_p(\delta_x, \delta_y) = \left(\sum_{i=1}^1 \sum_{j=1}^1 P_{i,j} d(x, y)^p \right)^{1/p} = d(x, y) \quad (12)$$

Quindi resta ben definito un gradiente $\nabla_x d(x, y) = \frac{x-y}{\|x-y\|_2}$ nelle fasi di ottimizzazione tramite discesa di gradiente.

Nelle moderne reti neurali generative, questa è una proprietà utile in quanto la distribuzione dei dati reali e quella generata tramite push-forward dallo spazio latente giacciono su varietà a bassa dimensione con supporti possibilmente disgiunti.

2.2 Regularizzazione di Cuturi

La risoluzione esatta dell'equazione LP di Kantorovich discreta è eseguita sfruttando il Network Simplex [7]. La complessità dell'algoritmo per un grafo con n campioni è dell'ordine di $\mathcal{O}(n^3 \log n)$.

Per superare il vincolo della complessità del programma lineare esatto, si aggiunge all'obiettivo una penalità convessa proporzionale all'entropia di Shannon della matrice di accoppiamento

$$L_C^\epsilon(a, b) = \min_{P \in U(a, b)} \{ \langle P, C \rangle - \epsilon H(P) \} \quad (13)$$

con $H(P) := - \sum_{i=1}^n \sum_{j=1}^m P_{i,j} (\log P_{i,j} - 1)$ ⁴ ed $\epsilon > 0$ parametro di regolarizzazione che modula il grado di smoothing. Il termine entropico rende il problema strettamente convesso e garantisce un'unica soluzione ottimale P^ϵ , che risulta strettamente positiva.

³Si osservi che su domini compatti, la convergenza rispetto alla metrica $\mathcal{W}_p(\alpha_k, \alpha) \rightarrow 0$ equivale alla convergenza debole di misure di probabilità ($\alpha_k \rightharpoonup \alpha$).

⁴si noti che per la regolarizzazione equivale $H(P) = - \sum_{i=1}^n \sum_{j=1}^m P_{i,j} \log P_{i,j} + 1$ e poiché la derivata e il punto di minimo di una funzione non cambiano con l'aggiunta di una costante, il piano di trasporto ottimo ottenuto con questa formula è identico a quello ricavato con l'entropia di Shannon standard. La costante serve a semplificare i passaggi algebrici nella derivazione del problema duale e dell'algoritmo di Sinkhorn ma non approfondiremo e si rimanda a [7]

Il parametro ϵ governa il bilanciamento tra l'accuratezza della misura di trasporto e la regolarità della soluzione. In particolare, per $\epsilon \rightarrow 0$ la soluzione P^ϵ converge alla soluzione del problema di Kantorovich originario, mentre per $\epsilon \rightarrow \infty$ la penalità entropica domina la funzione obiettivo e il piano converge ad $ab^\top$, che corrisponde alla condizione di totale indipendenza stocastica tra le due distribuzioni. Dalle condizioni di ottimalità si ricava la fattorizzazione

$$P^\epsilon = \text{diag}(u) K \text{diag}(v) \quad (14)$$

con $K_{ij} = \exp\left(-\frac{C_{ij}}{\epsilon}\right)$, cioè K è il kernel di Gibbs, e u, v sono vettori positivi scelti in modo da soddisfare i vincoli. Questa struttura è alla base dell'algoritmo di Sinkhorn, che determina iterativamente i vettori u e v mediante semplici operazioni di riscaldamento delle righe e delle colonne di K .

2.3 Proprietà di Differenziabilità

La regolarizzazione entropica $L_C^\epsilon(a, b)$ trasforma il problema di trasporto in una funzione liscia e differenziabile rispetto sia ai vettori di probabilità (a, b) sia alla matrice dei costi C .

Proposizione 2.1. *Per ogni $\epsilon > 0$, vale:*

1. *L'applicazione $(a, b) \mapsto L_C^\epsilon(a, b)$ è convessa e differenziabile. I gradienti rispetto ad a e b sono dati dai potenziali duali ottimi centrati (f^*, g^*)*

$$\nabla_a L_C^\epsilon(a, b) = f^* = \epsilon \log u^*, \quad \nabla_b L_C^\epsilon(a, b) = g^* = \epsilon \log v^* \quad (15)$$

2. *L'applicazione $C \mapsto L_C^\epsilon(a, b)$ è concava e differenziabile; il suo gradiente coincide con la matrice di trasporto ottimale primale P^**

$$\nabla_C L_C^\epsilon(a, b) = P^* \quad (16)$$

2.4 L'Algoritmo di Sinkhorn

Come osservato sopra la fattorizzazione di Gibbs (14) riduce il problema del trasporto alla ricerca di due vettori $u \in \mathbb{R}_+^n$ e $v \in \mathbb{R}_+^m$. Imponendo il rispetto delle condizioni di ammissibilità sulle righe e sulle colonne di P^ϵ deduciamo

$$P^\epsilon \mathbf{1}_m = a \implies \text{diag}(u) K v = a \implies u \odot (K v) = a \quad (17)$$

$$P^{\epsilon^\top} \mathbf{1}_n = b \implies \text{diag}(v) K^\top u = b \implies v \odot (K^\top u) = b \quad (18)$$

dove $\odot$ è il prodotto di Hadamard. Isolando u e v , si ricavano le iterazioni alternate di Sinkhorn

$$u^{(l+1)} = \frac{a}{K v^{(l)}} \quad (19)$$

$$v^{(l+1)} = \frac{b}{K^\top u^{(l+1)}} \quad (20)$$

L'algoritmo può essere interpretato intuitivamente come una successione di normalizzazioni alternate. Il primo aggiornamento modifica le righe del piano affinché rispettino la marginale sorgente a , mentre il secondo modifica le colonne affinché rispettino la marginale

target b . Ripetendo alternativamente queste due operazioni, il piano converge alla soluzione del problema di trasporto regolarizzato.

Si dimostra che l'algoritmo converge linearmente alla soluzione ottima (u^*, v^*) . Il teorema di Birkhoff-Hopf garantisce la convergenza interpretando le iterazioni come una contrazione rispetto alla metrica proiettiva di Hilbert $d_H(x, y)$

$$d_H(x, y) := \log \left(\frac{\max_i (x_i/y_i)}{\min_i (x_i/y_i)} \right) \quad (21)$$

Poiché il kernel di Gibbs K è strettamente positivo, l'applicazione ha un coefficiente di contrazione $\kappa(K) < 1$:

$$\kappa(K) = \frac{\sqrt{\eta(K)} - 1}{\sqrt{\eta(K)} + 1}, \quad \eta(K) = \max_{i,j,k,l} \frac{K_{i,k} K_{j,l}}{K_{j,k} K_{i,l}} \quad (22)$$

L'errore decade esponenzialmente ad ogni iterazione:

$$d_H(u^{(l)}, u^*) \leq \kappa(K)^l d_H(u^{(0)}, u^*) \quad (23)$$

Quando $\epsilon \rightarrow 0$, si ha $\eta(K) \rightarrow \infty$ e $\kappa(K) \rightarrow 1$. Questo spiega anche il rallentamento della convergenza numerica per valori di regolarizzazione molto piccoli.

Contestualmente per valori ridotti di ϵ , gli elementi esponenziali $\exp(-C_{ij}/\epsilon)$ generano underflow numerico, rendendo necessario il passaggio a implementazioni nel dominio logaritmico.

Dal punto di vista computazionale, osserviamo che Sinkhorn richiede solo moltiplicazioni matrice-vettore con complessità $\mathcal{O}(nm)$, che sono parallelizzabili su GPU.

3 Optimal Transport per il Domain Adaptation

Il trasporto ottimale trova una delle sue applicazioni nel Domain Adaptation (DA), dove l'obiettivo è trasferire la conoscenza su dominio sorgente a un dominio target caratterizzato da una distribuzione dei dati differente. Nel caso di Unsupervised Domain Adaptation (UDA), si assume di disporre di un insieme di campioni sorgente etichettati

$$\mathcal{D}_S = \{(x_i^S, y_i^S)\}_{i=1}^{n_S}$$

e di un insieme target non etichettato

$$\mathcal{D}_T = \{x_j^T\}_{j=1}^{n_T}.$$

Nel seguito le distribuzioni marginali associate alle istanze dei due domini saranno indicate con μ_S^X e μ_T^X , mentre le corrispondenti distribuzioni congiunte sulle coppie istanza-etichetta con μ_S^{XY} e μ_T^{XY} . Nel contesto della classificazione, l'ipotesi fondamentale è che i due domini condividano lo stesso spazio delle etichette $\mathcal{Y}$, ma che la distribuzione marginale delle osservazioni differisca ($\mu_S^X \neq \mu_T^X$).

Tale differenza, indicata come domain shift, può manifestarsi attraverso cambiamenti di illuminazione, sfondo, condizioni di acquisizione o, nel caso di interesse in questa tesina, attraverso cambiamenti di stile visivo.

Una rete addestrata minimizzando la perdita supervisionata sul dominio sorgente risolve il problema

$$\min_{\theta, \phi} \frac{1}{n_S} \sum_{i=1}^{n_S} \text{loss}(y_i^S, h_\phi(g_\theta(x_i^S))), \quad (24)$$

dove g_θ rappresenta l'estrattore di feature e h_ϕ il classificatore. Nulla, tuttavia, impone che la rappresentazione appresa sia adatta alla distribuzione target. L'obiettivo dell'adattamento consiste quindi nell'introdurre, oltre al termine supervisionato, un meccanismo capace di sfruttare le immagini target non etichettate.

3.1 Allineamento delle distribuzioni tramite Optimal Transport (OTDA)

Intuitivamente, se il domain shift non è troppo marcato, ci si aspetta che le rappresentazioni dei due domini abbiano distribuzioni vicine nello spazio delle feature. Indicando con

$$z_i^S = g_\theta(x_i^S), \quad z_j^T = g_\theta(x_j^T)$$

le rappresentazioni dei campioni, si costruiscono le misure empiriche di sorgente e target

$$\alpha_\theta^S = \frac{1}{n_S} \sum_{i=1}^{n_S} \delta_{z_i^S}, \quad \alpha_\theta^T = \frac{1}{n_T} \sum_{j=1}^{n_T} \delta_{z_j^T}$$

al fine di minimizzare la distanza di trasporto tra queste due distribuzioni

$$\mathcal{L}_{\text{OT}}(\theta) = \mathcal{W}_{2,\varepsilon}(\alpha_\theta^S, \alpha_\theta^T), \quad (25)$$

dove $\mathcal{W}_{2,\varepsilon}$ indica la perdita da minimizzare.

Nel caso discreto, definendo la matrice di costo $C_{ij} = \|z_i^S - z_j^T\|_2^2$, il problema di trasporto assume la forma

$$\mathcal{L}_{\text{OT}}(\theta) = \min_{P \in U(a,b)} \sum_{i,j} P_{ij} C_{ij} - \varepsilon H(P), \quad (26)$$

dove $U(a,b) = \{P \in \mathbb{R}_+^{n_S \times n_T} \mid P\mathbf{1}_{n_T} = a, P^\top \mathbf{1}_{n_S} = b\}$ è il poliedro dei vincoli associato alle distribuzioni marginali uniformi $a = \frac{1}{n_S} \mathbf{1}_{n_S}$ e $b = \frac{1}{n_T} \mathbf{1}_{n_T}$.

Il piano ottimo P descrive quindi la corrispondenza tra i campioni dei due domini sfruttando la geometria dello spazio delle feature. Nel contesto della domain adaptation, tale impostazione è alla base degli approcci OTDA di Courty et al. [8]. L'allineamento delle sole distribuzioni marginali presenta tuttavia una limitazione importante in quanto la vicinanza geometrica non garantisce che vengano associate rappresentazioni appartenenti alla stessa classe, cioè un trasporto basato esclusivamente sulle feature potrebbe associare un campione sorgente di una classe a un campione target di una classe diversa solo perché vicini nello spazio delle feature.

Questo problema motiva l'introduzione di informazione discriminativa direttamente nel costo di trasporto, principio alla base della formulazione JDOT.

3.2 JDOT

Per incorporare l'informazione discriminativa nel trasporto, Courty et al. hanno proposto il metodo Joint Distribution Optimal Transportation (JDOT) [9], il cui obiettivo è allineare congiuntamente le distribuzioni delle istanze e delle relative etichette. Poiché le etichette target non sono disponibili, la distribuzione congiunta target viene approssimata tramite le predizioni di un classificatore f_ϕ

$$\hat{\mu}_T^{XY} = \frac{1}{n_T} \sum_{j=1}^{n_T} \delta_{(x_j^T, f_\phi(x_j^T))}.$$

Il costo di trasporto tra un campione sorgente (x_i^S, y_i^S) e uno target $(x_j^T, f_\phi(x_j^T))$ combina due contributi

$$C_{ij} = \alpha d(x_i^S, x_j^T) + \beta L_{\text{class}}(y_i^S, f_\phi(x_j^T)), \quad (27)$$

dove $d(\cdot, \cdot)$ è una metrica di distanza nello spazio osservato (tipicamente euclidea quadra), L_{class} denota la perdita di classificazione, mentre α e β sono coefficienti positivi di bilanciamento. Il piano di accoppiamento viene ottenuto risolvendo

$$P_\varepsilon^* = \arg \min_{P \in U(a,b)} [\langle P, C \rangle - \varepsilon H(P)]. \quad (28)$$

L'introduzione del termine semantico modifica la natura del trasporto in quanto una corrispondenza non è più favorita solamente dalla vicinanza geometrica, ma anche dalla compatibilità delle etichette.

Intuitivamente in presenza di un forte domain shift, il classificatore f_ϕ tenderà a produrre inizialmente predizioni inaffidabili sul target. Ciò potrebbe indurre il piano P^* ad accoppiare campioni appartenenti a classi diverse ma erroneamente etichettati, generando un circolo di accumulo dell'errore (confirmation bias) durante l'aggiornamento dei parametri.

3.3 DeepJDOT

DeepJDOT, proposto da Damodaran et al. [5], estende JDOT all’addestramento di reti neurali, apprendendo simultaneamente una rappresentazione discriminativa nello spazio latente $z = g_\theta(x)$ e il classificatore $h_\phi(z)$. Indicando con

$$z_i^S = g_\theta(x_i^S), \quad z_j^T = g_\theta(x_j^T),$$

la matrice di costo viene costruita nello spazio delle feature come

$$C_{ij} = \alpha_{\text{feat}} \|z_i^S - z_j^T\|_2^2 + \alpha_{\text{class}} L_{\text{class}}(y_i^S, h_\phi(z_j^T)). \quad (29)$$

Nel caso della cross-entropy, la perdita di classificazione è data da

$$L_{\text{class}}(y_i^S, h_\phi(z_j^T)) = -\log p_\phi(y_i^S | z_j^T).$$

L’addestramento della rete avviene minimizzando la funzione obiettivo complessiva

$$\mathcal{L}(\theta, \phi) = \frac{1}{n_S} \sum_{i=1}^{n_S} L_{\text{class}}(y_i^S, h_\phi(g_\theta(x_i^S))) + \mathcal{L}_{\text{DeepJDOT}}(\theta, \phi), \quad (30)$$

dove il secondo termine è la perdita di trasporto congiunto calcolata sul piano ottimo P^*

$$\mathcal{L}_{\text{DeepJDOT}}(\theta, \phi) = \sum_{i,j} P_{ij}^* [\alpha_{\text{feat}} \|z_i^S - z_j^T\|_2^2 + \alpha_{\text{class}} L_{\text{class}}(y_i^S, h_\phi(z_j^T))] \quad (31)$$

Il calcolo di P^* e l’ottimizzazione vengono eseguiti su mini-batch tramite l’algoritmo di Sinkhorn. Il metodo riduce significativamente il disallineamento tra classi rispetto al trasporto puramente marginale, ma rimane vulnerabile all’accumulo di errori in presenza di una confidenza predittiva iniziale ridotta sul target, richiedendo anche un’attenta calibrazione degli iperparametri α_{feat} , α_{class} ed ε .

3.4 Rappresentazioni prototipiche

Nel caso di un dominio target caratterizzato da un forte shift, il piano calcolato su un singolo minibatch può essere sensibile alle fluttuazioni casuali del campionamento.

Una possibilità per ridurre la varianza campionaria consiste nel sostituire la distribuzione sorgente empirica con una rappresentazione compatta costituita da prototipi di classe. Sia $\mathcal{C} = \{1, \dots, K\}$ l’insieme delle classi. Per una classe k , definiamo il prototipo sorgente

$$p_k = \frac{1}{|\mathcal{D}_{S,k}|} \sum_{x_i^S \in \mathcal{D}_{S,k}} g_\theta(x_i^S). \quad (32)$$

Il prototipo può essere interpretato come una rappresentazione sintetica della posizione media della classe nello spazio latente. In presenza di più domini sorgente, tale costruzione può essere effettuata dopo aver aggregato i campioni appartenenti alla stessa classe oppure separatamente per ciascun dominio.

Dati i prototipi $P_S = \{p_1, \dots, p_K\}$ e un minibatch target $Z_T = \{z_1^T, \dots, z_{n_T}^T\}$, si costruisce la matrice di costo come

$$C_{kj} = d(p_k, z_j^T)^2. \quad (33)$$

Il piano viene poi ottenuto risolvendo

$$\Pi^* = \arg \min_{\Pi \in U(a,b)} [\langle \Pi, C \rangle - \varepsilon H(\Pi)] . \quad (34)$$

Osserviamo che rispetto a DeepJDOT, il costo non contiene direttamente un termine di classificazione calcolato su ogni coppia sorgente-target. L'informazione semantica viene invece introdotta indirettamente attraverso la costruzione dei prototipi p_k . Questo tipo di approccio elimina il confirmation bias (non si usano predizioni provvisorie del target) e abbatta il costo computazionale, di contro riduce l'intera distribuzione di ciascuna classe a un singolo punto, ossia cancella la varianza intra-classe e l'algoritmo di Sinkhorn agisce di fatto come un'assegnazione morbida delle feature target a riferimenti prefissati, più che come un allineamento tra distribuzioni empiriche complesse.

3.5 Adattamento nel caso multi-sorgente

Fin qui abbiamo trattato il caso di un singolo dominio sorgente; generalizziamo adesso al caso multi-sorgente. Disponendo di M domini sorgente congiunti al dominio target, l'insieme dei dati sorgente è dato da

$$\mathcal{D}_S = \bigcup_{m=1}^M \mathcal{D}_{S_m} .$$

L'idea per ricondursi alla formulazione a singola sorgente è interpretare l'unione dei domini come un'unica distribuzione sorgente globale, data dalla combinazione convessa delle singole distribuzioni sorgenti

$$\mu_S = \sum_{m=1}^M \lambda_m \mu_{S_m} \quad \text{con} \quad \sum_{m=1}^M \lambda_m = 1 \quad \text{e} \quad \lambda_m \geq 0 \quad \forall m$$

3.6 Allineamento tramite prototipi multi-dominio

Definendo il prototipo della classe k nel dominio sorgente m come

$$p_{m,k} = \frac{1}{|\mathcal{D}_{S_m,k}|} \sum_{x_i \in \mathcal{D}_{S_m,k}} g_\theta(x_i), \quad (35)$$

per $m = 1, \dots, M$ e $k = 1, \dots, K$, si possono considerare due strategie di allineamento

1. Prototipi fusi (allineamento globale): si costruisce un unico prototipo per classe mediando i centroidi calcolati sui singoli domini

$$p_k^{\text{fused}} = \frac{1}{M} \sum_{m=1}^M p_{m,k}, \quad (36)$$

definendo la misura discreta $\alpha_S^{\text{fused}} = \frac{1}{K} \sum_{k=1}^K \delta_{p_k^{\text{fused}}}$. L'adattamento è dato dalla risoluzione di un singolo problema di trasporto ottimo rispetto al batch target $\alpha_T = \frac{1}{n_T} \sum_{j=1}^{n_T} \delta_{z_j^T}$

$$\mathcal{L}_{\text{fused}} = \mathcal{W}_{2,\varepsilon}(\alpha_S^{\text{fused}}, \alpha_T) . \quad (37)$$

Questa formulazione si basa sull'idea che la distanza intra-classe dovuta alle varianze delle rappresentazioni nei diversi domini sia trascurabile rispetto alla distanza inter-classe che separa categorie semantiche diverse, così che il prototipo medio conservi una chiara separabilità geometrica.

2. Prototipi separati (allineamento pairwise): si mantengono distinte le rappresentazioni dei singoli domini sorgente associando a ciascun dominio la misura $\alpha_{S_m}^{\text{proto}} = \frac{1}{K} \sum_{k=1}^K \delta_{p_{m,k}}$. La perdita complessiva è ottenuta mediando i singoli problemi di trasporto calcolati indipendentemente per ciascun dominio sorgente contro il target:

$$\mathcal{L}_{\text{pairwise}} = \frac{1}{M} \sum_{m=1}^M \mathcal{W}_{2,\varepsilon}(\alpha_{S_m}^{\text{proto}}, \alpha_T) \quad (38)$$

La differenza tra le due impostazioni risiede nella rappresentazione della sorgente, poiché mentre la fusione α_S^{fused} ibrida le sorgenti per ottenere una rappresentazione intermedia, l'approccio pairwise preserva le caratteristiche di ciascun dominio, consentendo al target di allinearsi ad un riferimento più omogeneo.

3.7 Multi-Source DeepJDOT

Nell'adattamento multi-sorgente, trattare l'unione dei domini sorgente come un'unica distribuzione empirica può causare interferenze durante la risoluzione del trasporto ottimo.

A causa del divario stilistico tra le sorgenti, istanze appartenenti alla medesima classe non coincidono nello spazio latente e competono per la medesima massa target.

Poiché la capacità di ricezione di ciascun punto target è rigidamente vincolata dalla marginale, una volta saturata dal campione sorgente a esso geometricamente più prossimo, la massa residua degli altri campioni della stessa classe viene forzatamente deviata verso altri elementi target, anche se semanticamente disomogenei. L'imposizione dei vincoli di conservazione induce così accoppiamenti spuri tra classi distinte e genera gradienti di aggiornamento contrastanti durante l'ottimizzazione.

Una soluzione naturale consiste nel decomporre il problema in un allineamento a coppie (Pairwise MS-DeepJDOT). Dati M domini sorgente, si definiscono M matrici di costo distinte

$$C_{ij}^{(m)} = \alpha_{\text{feat}} \|z_i^{S_m} - z_j^T\|_2^2 + \alpha_{\text{class}} L_{\text{class}}(y_i^{S_m}, h_\phi(z_j^T)), \quad m = 1, \dots, M, \quad (39)$$

calcolate tra le rappresentazioni del dominio sorgente S_m e il batch target T . Il costo è poi ottenuto mediando i singoli termini di trasporto

$$\mathcal{L}_{\text{MS-DeepJDOT}}(\theta, \phi) = \frac{1}{M} \sum_{m=1}^M \sum_{i,j} (P_{(m)}^*)_{ij} C_{ij}^{(m)}, \quad (40)$$

dove ciascun piano $P_{(m)}^*$ è la soluzione regolarizzata del trasporto ottimo tra il dominio sorgente S_m e il target T .

L'ipotesi è quindi che, risolvendo M problemi di trasporto indipendenti, ciascuna sorgente trasferisca il proprio segnale geometrico e semantico in modo da rendere la retropropagazione del gradiente più stabile.

3.8 Baricentri di Wasserstein per il Domain Adaptation Multi-Sorgente

Per sintetizzare M distribuzioni sorgente $\mu_{S_1}, \dots, \mu_{S_M}$ preservando la struttura geometrica sottostante, un'altro metodo a cui è possibile ricorrere è quello dei Baricentri di Wasserstein, introdotto da Agueh e Carlier in [4].

Dati i pesi baricentrici $\lambda \in \Sigma_M$ associati ai domini sorgente (tipicamente $\lambda_m = 1/M$), il baricentro di Wasserstein μ_B è la misura di probabilità che minimizza la somma ponderata delle distanze di Wasserstein

$$\mu_B = \arg \min_{\mu} \sum_{m=1}^M \lambda_m \mathcal{W}_2^2(\mu, \mu_{S_m}). \quad (41)$$

Nel discreto il baricentro continuo viene approssimato tramite una misura empirica a supporto libero $X_B = \{w_1, \dots, w_B\} \subset \mathbb{R}^d$, ovvero $\mu_B = \frac{1}{B} \sum_{k=1}^B \delta_{w_k}$.

La procedura si articola in due fasi

1. stima del baricentro: ad ogni iterazione, le posizioni dei punti di supporto X_B vengono ottimizzate mediante discesa di gradiente per minimizzare la divergenza di Sinkhorn rispetto ai batch estratti dai singoli domini sorgente

$$\min_{X_B} \sum_{m=1}^M \frac{1}{M} \mathcal{W}_{2,\varepsilon} \left(\frac{1}{B} \sum_{k=1}^B \delta_{w_k}, \alpha_{S_m} \right). \quad (42)$$

2. Allineamento al target: una volta identificata μ_B , si definisce la funzione di perdita di adattamento come la distanza di trasporto tra il baricentro stimato e la distribuzione empirica delle feature target

$$\mathcal{L}_{\text{bary}}(\theta) = \mathcal{W}_{2,\varepsilon}(\mu_B, \alpha_T). \quad (43)$$

Pur catturando la geometria continua delle sorgenti senza richiedere supervisione, il calcolo del baricentro richiede una costosa ottimizzazione interna e, non vincolando le classi, può generare scambi semantici in presenza di divari visivi estremi.

4 Esperimento

Per valutare l’efficacia delle diverse formulazioni di trasporto ottimo in presenza di un marcato divario distributivo, le strategie descritte sono state testate sul benchmark PACS. A differenza di dataset storici come Office-Caltech, MNIST/USPS o Office-Home in cui l’OT è stato testato ([5], [8]), dove le differenze tra domini riguardano fondamentalmente condizioni di illuminazione, sfondo o shift stilistico contenuto, PACS introduce uno shift molto più radicale tra stili visivi differenti. Nelle sezioni successive diversi approcci basati sull’OT vengono confrontati a parità di architettura e protocollo di ottimizzazione.

4.1 Dataset e task

PACS (Photo, Art Painting, Cartoon, Sketch) è un dataset introdotto per valutare modelli nel task di Domain Generalization [10], scenario in cui il modello viene addestrato esclusivamente su domini sorgente e valutato su domini target non osservati durante l’addestramento.

Il dataset contiene 9.991 immagini suddivise in:

- 4 domini: Photo (1.670 immagini), Art Painting (2.048 immagini), Cartoon (2.344 immagini) e Sketch (3.929 immagini).
- 7 classi: cane, elefante, giraffa, chitarra, cavallo, casa e persona.

A differenza di benchmark come Office-Home, in cui la transizione tra stili mantiene comunque texture ricche, sfondi articolati e pattern cromatici complessi, PACS sposta la sfida dall’adattamento alla comprensione della struttura geometrica degli oggetti.

La presenza del dominio Sketch elimina completamente colore, shading e texture, riducendo la rappresentazione visiva al solo tratto continuo.


Questo rende PACS un banco di prova interessante per il trasporto ottimale in quanto l’estrema eterogeneità tra i domini genera distribuzioni con supporti disgiunti nello spazio latente; condizione in cui, come già accennato nella sezione 2, l’OT contrariamente alle divergenze tradizionali fornisce gradienti informativi, costringendo il modello a superare il texture bias per individuare invarianti geometriche pure.

Al contempo, un’astrazione così drastica rende le predizioni preliminari della rete sul target particolarmente inaffidabili nelle fasi iniziali di addestramento. L’indagine empirica consente dunque di verificare come tali dinamiche interagiscano e in quale misura la modellazione della misura sorgente incida sulla robustezza complessiva dell’allineamento.

4.1.1 Quantificazione empirica del domain shift

Al fine di misurare quantitativamente l’entità della discrepanza tra i domini di PACS, è stata calcolata la matrice delle distanze di Wasserstein ($\mathcal{W}_{2,\varepsilon}$ con $\varepsilon = 0.05$) sulle feature estratte dalla backbone pre-addestrata prima dell’adattamento.


I valori riportati nella Tabella 1 evidenziano che la configurazione target Sketch presenta la maggiore distanza media rispetto ai domini sorgente (0.4768 contro 0.3794 di Cartoon), raggiungendo la massima divergenza rispetto a Photo (0.5270). Questo dato supporta quantitativamente la scelta di Cartoon e Sketch come rappresentativi, rispettivamente, di un domain shift moderato e di un domain shift severo.



(a) photo (giraffe)



(b) sketch (guitar)



(c) cartoon (house)



(d) painting (dog)

Figura 3: Esempi di immagini rappresentative per ciascuno dei quattro domini del dataset PACS.

Tabella 1: Matrice delle distanze di Wasserstein regolarizzate tra le distribuzioni dei domini in PACS.

Dominio	Photo	Art Painting	Cartoon	Sketch
Photo	0.0000	0.3248	0.4002	0.5270
Art Painting	0.3248	0.0000	0.3230	0.4883
Cartoon	0.4002	0.3230	0.0000	0.4150
Sketch	0.5270	0.4883	0.4150	0.0000

4.2 Scelte sperimentali

L'esperimento segue un protocollo di domain adaptation multi-sorgente non supervisionata, secondo lo schema leave one domain out, ossia tre dei quattro domini disponibili (Photo, Art Painting, Cartoon, Sketch) vengono utilizzati come sorgenti etichettate, mentre il quarto è trattato come dominio target, di cui sono disponibili solo le immagini (ma non le etichette delle immagini) durante l'addestramento.

L'indagine sperimentale è stata limitata alle due configurazioni target Cartoon e Sketch, scelte sia perché caratterizzate dal domain shift più marcato, sia per i vincoli associati ai tempi massimi di esecuzione delle sessioni GPU su Colab e Kaggle.

Tutti i metodi condividono la medesima architettura, procedura di ottimizzazione e struttura di training, in modo da isolare l'effetto del solo meccanismo di adattamento

- **Backbone:** Si è usata una ResNet-18 pre-addestrata su ImageNet, privata del layer finale, utilizzata come estrattore di un vettore di feature in $\mathbb{R}^{512}$. Sopra di essa è collocato un singolo livello lineare (7 classi) inizializzato casualmente e addestrato da zero. È stata scelta ResNet-18 rispetto ad AlexNet (utilizzata originariamente da Li et al. [10] per il benchmark PACS) perché offre un miglior compromesso tra capacità rappresentativa e costo computazionale.
- **Ottimizzatore:** Adam con learning rate fisso a 1×10^{-4} applicato a tutti i parametri del modello.

- Batch size: 256 campioni per dominio sorgente (tramite unione e aggregazione dei campioni provenienti dai tre domini sorgente in un unico batch) e per il batch target. Batch di queste dimensioni si sono rivelati necessari per garantire una copertura statisticamente solida delle celle dominio $\times$ classe su cui si basano le stime dei prototipi utilizzate dai metodi OT descritti più sotto; batch piccoli (32-64) producevano stime dei centroidi rumorose.
- Data Augmentation: Tutte le immagini vengono ridimensionate alla risoluzione di 224×224 pixel. Durante la fase di addestramento, sia sui domini sorgente sia sul target, viene applicato un data augmentation costituito da ribaltamento orizzontale casuale (0.5) e dalla standardizzazione dei canali RGB mediante i valori medi μ e deviazioni standard σ di ImageNet. In fase di test sul dominio target vengono applicati unicamente il ridimensionamento e la normalizzazione.
- Regime di addestramento: 10 epoche complessive, di cui 3 iniziali di warm-up guidate dalla sola cross-entropy supervisionata. Dalla quarta epoca, il peso dell'adattamento cresce linearmente fino al valore di regime $w_{da} \cdot \lambda_{da}$, dove $w_{da} \in [0, 1]$ regola la transizione graduale e λ_{da} è un coefficiente di scala fisso (0.10 per le formulazioni DeepJDOT e 0.15 per i metodi prototipici e baricentrici).
- Regularizzazione: Gradient clipping con norma massima pari a 5.0, applicato uniformemente per prevenire instabilità numeriche dovute a gradienti elevati nelle fasi iniziali dell'allineamento.
- Normalizzazione delle feature: In tutti i metodi basati su optimal transport, le feature vengono normalizzate (L_2) prima del calcolo di qualunque costo o distanza. Questa scelta evita che le distanze euclidee tra feature non vincolate in norma assumano scale molto ampie e rendano numericamente instabile il calcolo del trasporto tramite Sinkhorn.

Ogni combinazione (metodo, dominio target) è stata ripetuta su tre seed differenti (0, 1, 2), riportando media e deviazione standard dell'accuratezza nel dominio target.

4.3 Metodi

4.3.1 Baseline (ce)

Il modello è addestrato con la sola cross-entropy supervisionata sui domini sorgente, senza alcun contatto con le immagini del dominio target durante il training. Costituisce il limite inferiore di riferimento standard in letteratura per la domain adaptation.

4.3.2 CE con ricalibrazione delle statistiche BatchNorm (ce_{BN})

Questa variante esegue un forward pass dei dati target in modalità train. Pur mantenendo la stessa loss di ce e senza calcolare gradienti sul target, il passaggio aggiorna le medie e varianze mobili di BatchNorm, ricalibrando la normalizzazione interna sulla distribuzione target (approccio AdaBN). Questo metodo serve a isolare il beneficio passivo dato dalla semplice ricalibrazione statistica ottenuta avendo accesso alle immagini del target, distinguendolo dai contributi forniti dalle tecniche di allineamento esplicito.

4.3.3 OT con prototipi di classe fusi ($proto_{OT}$)

Mantiene una memoria dei centroidi di classe aggiornata a ogni batch tramite media mobile esponenziale (momentum 0.95), mediando uniformemente i centroidi dei singoli domini sorgente. Il trasporto ottimo viene calcolato tra questi prototipi globali e le feature del batch target tramite la divergenza di Sinkhorn (libreria GeomLoss, con parametro blur pari a 0.10 e scaling pari a 0.9), impiegando tutte le categorie semantiche inizializzate nella memoria per evitare distorsioni da classi temporaneamente assenti nel singolo step.

4.3.4 OT con prototipi di classe pairwise ($proto_{OT}^{PW}$)

Mantiene memorie prototipiche distinte per ciascun dominio sorgente, aggiornate con media mobile esponenziale. Risolve tre problemi di trasporto ottimi indipendenti, uno per ciascun dominio sorgente contro il target, e calcola la perdita finale mediando i tre costi risultanti.

4.3.5 DeepJDOT aggregato ($deepjdot$)

Costruisce il piano di trasporto ottimo primale direttamente sulle singole istanze, trattando l'insieme dei domini sorgente come un'unica distribuzione combinata. La matrice di costo bilancia la distanza geometrica euclidea quadra e la perdita di classificazione sulle predizioni target con parametri $\alpha_{\text{feat}} = 1.0$ e $\alpha_{\text{class}} = 1.0$, troncando la cross-entropy a 5.0. Il piano viene calcolato tramite algoritmo di Sinkhorn con criterio di arresto anticipato (tolleranza 10^{-4} , regolarizzazione $\varepsilon = 0.10$) previa sottrazione del valore minimo della matrice dei costi.

4.3.6 DeepJDOT pairwise multi-sorgente ($deepjdot_{PW}$)

Risolve tre problemi di trasporto congiunto indipendenti, uno per ciascun dominio sorgente verso il batch target, mediando i rispettivi costi. La matrice di costo per ciascun dominio adotta i parametri $\alpha_{\text{feat}} = 1.0$, $\alpha_{\text{class}} = 1.0$ e regolarizzazione entropica $\varepsilon = 0.05$.

4.3.7 Baricentro di Wasserstein ($Wbarycenters_{OT}$)

A ogni iterazione, estrae le feature dei differenti domini sorgente ed esegue un'ottimizzazione interna a supporto libero (64 punti di supporto in $\mathbb{R}^{512}$, ottimizzati con 8 passi di Adam e learning rate pari a 0.05) per calcolare il baricentro di Wasserstein continuo delle misure sorgente tramite GeomLoss. Successivamente allinea le feature del batch target al baricentro stimato tramite divergenza di Sinkhorn.

Metodo	Informazione target	Meccanismo di adattamento
ce	nessuna	nessuno
ce_{BN}	feature target	ricalibrazione BatchNorm
$deepjdot$	feature target	OT congiunto su sorgenti aggregate
$deepjdot_{PW}$	feature target	OT congiunto separato per dominio
$Wbarycenters_{OT}$	feature target	OT verso il baricentro di Wasserstein delle sorgenti
$proto_{OT}$	feature target	OT su prototipi fusi
$proto_{OT}^{PW}$	feature target	OT su prototipi separati per dominio

4.4 Risultati e discussione

La Tabella 2 riporta l’accuratezza media e la deviazione standard su tre seed casuali per ciascuna configurazione analizzata.

Tabella 2: Accuratezza media ($\pm$ deviazione standard su 3 seed) sul test set del dominio target.

Metodo	Cartoon	Sketch	Media sui 2 target
ce	72.60% $\pm$ 2.28%	62.99% $\pm$ 1.43%	67.79%
ce_{BN}	78.34% $\pm$ 1.17%	63.93% $\pm$ 0.91%	71.13%
$deepjdot$	78.67% $\pm$ 0.40%	64.23% $\pm$ 7.37%	71.45%
$deepjdot_{PW}$	84.81% $\pm$ 0.16%	68.59% $\pm$ 1.95%	76.70%
$Wbarycenters_{OT}$	84.91% $\pm$ 0.42%	70.64% $\pm$ 0.61%	77.77%
$proto_{OT}$	84.60% $\pm$ 0.88%	73.67% $\pm$ 1.98%	79.13%
$proto_{OT}^{PW}$	84.22% $\pm$ 0.82%	73.73% $\pm$ 1.90%	78.97%

Chiaramente, prima di trarre qualsiasi conclusione dai risultati, va evidenziato il limite statistico rappresentato da un campione di sole tre run. Sebbene i seed siano stati fissati per garantire la riproducibilità, lievi differenze potrebbero comunque essere attribuite alla varianza statistica. Fatta questa premessa metodologica, nel seguito gli esiti sperimentali vengono interpretati in relazione ai quesiti iniziali.

Un primo risultato rilevante emerge dal confronto tra la baseline ce e ce_{BN} , dove si osserva che la ricalibrazione passiva delle statistiche di BatchNorm recupera 5.74 punti percentuali su Cartoon, ma solo 0.94 su Sketch. Ciò suggerisce che la correzione della normalizzazione è efficace su shift moderati, ma molto meno in presenza di divari stilistici severi.

Per quanto riguarda l’analisi dei metodi basati sul trasporto ottimale si possono evidenziare tre aspetti rilevanti.

La prima riguarda il comportamento di DeepJDOT e il ruolo determinante della decomposizione pairwise. Quando il termine semantico viene riequilibrato rispetto alla distanza geometrica ($\alpha_{\text{class}} = 1.0$), la variante aggregata globale ($deepjdot$) subisce una sensibile perdita di efficacia. Sul target Cartoon ottiene solo il 78.67% (un valore sostanzialmente

uguale alla semplice ricalibrazione BatchNorm), mentre su Sketch scende al 64.23% facendo registrare un’elevata instabilità (deviazione standard del 7.37%, con una run crollata al 54.16%). Questo fallimento illustra una vulnerabilità del trasporto congiunto a livello di istanza quando sorgenti eterogenee vengono forzate all’interno dei medesimi vincoli marginali. Specialmente nella run sopracitata è evidente che i campioni sorgente con caratteristiche visive discordanti inducono accoppiamenti errati guidati dalle previsioni target inizialmente rumorose, innescando un confirmation bias distruttivo.

La formulazione pairwise ($deepjdot_{PW}$) prova ad affrontare alla radice questa interferenza, risolvendo il trasporto ottimo in modo isolato per ciascun dominio sorgente, evitando così la competizione tra distribuzioni visive discordanti. In questo caso le prestazioni su Cartoon aumentano di 6.14 punti percentuali, attestandosi all’84.81% con una deviazione standard contenuta allo 0.16%, mentre su Sketch salgono al 68.59% (+4.36% rispetto alla formulazione aggregata).

La seconda evidenza riguarda la superiorità dei metodi prototipici sul target Sketch. Con un’accuratezza del 73.67% per la variante a fusione globale e del 73.73% per quella pairwise, i metodi prototipici distanziano tutte le altre formulazioni, superando il baricentro di Wasserstein di circa 3 punti percentuali e DeepJDOT pairwise di oltre 5 punti. Il vantaggio principale risiede verosimilmente nell’esclusione delle predizioni target dalla funzione di costo, una proprietà che rende i prototipi immuni al confirmation bias.

Inoltre, il confronto tra $proto_{OT}$ e $proto_{OT}^{PW}$ mostra prestazioni fondamentalmente equivalenti su entrambi i target (84.60% contro 84.22% su Cartoon; 73.67% contro 73.73% su Sketch). Ne segue che a differenza di DeepJDOT, in cui la separazione pairwise era significativa, nei metodi prototipici la fusione globale dei centroidi agisce già come un regolarizzatore naturale, rendendo di fatto ininfluenza la separazione dei singoli domini sorgente.

La terza dinamica riguarda il baricentro di Wasserstein ($Wbarycenters_{OT}$). Su Cartoon, dove i domini mantengono una relativamente buona continuità geometrica, l’interpolazione continua nello spazio delle distribuzioni ottiene la prestazione migliore in assoluto 84.91% $\pm$ 0.42% allineandosi sostanzialmente ai metodi prototipici. Su Sketch, al contrario, il metodo si ferma al 70.64%. Questa sensibile flessione rispetto ai metodi prototipici si può probabilmente spiegare alla luce del fatto che il baricentro di Wasserstein allinea le distribuzioni senza conoscere le etichette; quindi nel dominio Sketch, dove i contorni di classi diverse sono molto simili nello spazio latente, è più propenso a confondere categorie semanticamente diverse ma con forme simili.

Sotto il profilo computazionale, vale infine sottolineare il trade-off operativo tra i metodi esaminati. Mentre il baricentro di Wasserstein richiede un’ottimizzazione interna di 8 passi di gradiente per mini-batch su 64 punti di supporto, i prototipi fusi ($proto_{OT}$) ottengono risultati superiori su Sketch e del tutto comparabili su Cartoon tramite un semplice aggiornamento vettoriale a costo di calcolo trascurabile, rappresentando la soluzione più solida ed efficiente per le applicazioni pratiche.

4.5 Conclusioni

L'indagine sperimentale condotta supporta l'ipotesi che il trasporto ottimale costituisca un paradigma efficace per l'adattamento di dominio multi-sorgente non supervisionato. Di seguito riassumiamo le 3 dinamiche che l'indagine ha evidenziato

1. L'efficacia dell'adattamento varia con l'entità del divario visivo. Su Cartoon, dove permangono colori, ombreggiature e texture, l'allineamento tramite OT si dimostra solido e sia il baricentro continuo sia DeepJDOT pairwise sfiorano l'85%, superando la baseline di oltre 12 punti percentuali. Su Sketch, anche se i metodi producano un guadagno statisticamente significativo rispetto al riferimento supervisionato del 62.99%, questo è più contenuto. DeepJDOT aggregato si arresta al 64.23% a causa del confirmation bias innescato da predizioni target inaffidabili, mentre il baricentro continuo si ferma al 70.64%, penalizzato dalla somiglianza geometrica tra i contorni di classi differenti.
2. Il vantaggio dei metodi prototipici su Sketch (circa 73.7%) scaturisce da una deliberata semplificazione del problema. Ancorando il trasporto a centroidi di classe ed escludendo i risultati del classificatore dal costo, il metodo ottiene un'immunità al confirmation bias.
3. Il livello di dettaglio con cui viene modellata la sorgente determina la necessità o meno di una formulazione pairwise. Nel trasporto a livello di istanza (DeepJDOT), separare i domini sorgente è indispensabile per evitare che istanze di stili visivi diversi, spinte dai vincoli marginali, competano per la stessa massa target. Nei metodi prototipici, al contrario, l'aggregazione globale dei centroidi opera una naturale regolarizzazione geometrica che assorbe le variazioni stilistiche delle singole sorgenti, rendendo superfluo il ricorso a trasporti indipendenti.

In sintesi, il trasporto ottimale si conferma un potente paradigma di allineamento in presenza di una base visiva comune, mentre mostra una significativa ma più contenuta efficacia dinanzi a forme di astrazione geometrica radicale per la sua maggiore fragilità al confirmation bias nelle varianti congiunte e a scambi semantici nelle varianti non supervisionate.

Riferimenti bibliografici

- [1] F. Santambrogio, *Optimal Transport for Applied Mathematicians: Calculus of Variations, PDEs, and Modeling*, Birkhäuser, 2015.
- [2] Y. Brenier, Polar factorization and monotone rearrangement of vector-valued functions, *Communications on Pure and Applied Mathematics*, vol. 44, no. 4, pp. 375–417, 1991.
- [3] M. Cuturi, Sinkhorn distances: Lightspeed computation of optimal transport, in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 26, 2013, pp. 2292–2300.
- [4] M. Agueh and G. Carlier, Barycenters in the Wasserstein space, *SIAM Journal on Mathematical Analysis*, vol. 43, no. 2, pp. 904–924, 2011.

- [5] B. B. Damodaran, B. Kerdoncuff, V. Gousseau, and N. Courty, DeepJDOT: Deep joint distribution optimal transport for unsupervised domain adaptation, in Proceedings of the European Conference on Computer Vision (ECCV), 2018, pp. 447–463.
- [6] M. Arjovsky, S. Chintala, and L. Bottou, Wasserstein generative adversarial networks, in International Conference on Machine Learning (ICML), PMLR, 2017, pp. 214–223.
- [7] G. Peyré and M. Cuturi, Computational Optimal Transport: With Applications to Data Science, Foundations and Trends in Machine Learning, vol. 11, no. 5-6, pp. 355–607, 2019.
- [8] N. Courty, R. Flamary, D. Tuia, and A. Rakotomamonjy, Optimal transport for domain adaptation, IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 39, no. 9, pp. 1853–1865, 2016.
- [9] N. Courty, R. Flamary, A. Habrard, and A. Rakotomamonjy, Joint distribution optimal transport for domain adaptation, in Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017.
- [10] D. Li, Y. Yang, Y.-Z. Song, and T. M. Hospedales, Deeper, broader and artier domain generalization, in Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017, pp. 5581–5590.